

基于参数高效 BERT 适配的零样本文本-视频检索

— Eureka-from-CLIP 课程设计报告

张思远[†] 程亚迪[†]

浙江工业大学

{zhangsiyuan,chengyadi}@zjut.edu.cn

2026 年 6 月 16 日

摘要

本文介绍 Eureka-from-CLIP，一个在受限资源下将 CLIP 的固定文本编码器替换为轻量级 BERT 编码器的零样本文本-视频检索框架。通过参数高效的跨模态对齐，我们首先在 COCO Captions 上使用仅 1.35M 可训练的 LoRA 参数将 BERT 适配到 CLIP 的冻结视觉空间，在 Flickr30k 文本-图像检索中超越 CLIP 原生文本编码器（60.48% 对比 57.90%）。随后，我们通过 Stack LoRA 进行视频领域适配：冻结 COCO 训练的适配器，在 MSR-VTT 上叠加一个更小的秩为 2 的 Stack（0.63M 可训练参数）。最终模型在 MSVD 零样本视频检索中超过 CLIP（28.13% 对比 27.01% t2i R@1），而适配训练开销仅为完整微调的一小部分。我们的非对称队列设计通过遮蔽过时的文本嵌入同时保留新鲜的图像队列，弥补了受限 GPU 内存下小批量大小的不足。本工作为在有限计算资源下用任意 BERT 变体替换 CLIP 文本编码器提供了一种实用方案，适用于图像和视频检索，并可通过 BERT 的多语言变体自然地扩展到多语言场景。

一、引言

CLIP [1] 已成为零样本文本-视频检索的事实标准骨干网络：逐帧的 CLIP 视觉嵌入经过均值池化得到视频表示，然后与 CLIP 文本编码器进行对比以实现检索 [16]。然而，CLIP 的文本编码器是一个固定组件——它无法被轻松替换或扩展以支持多语言查询、领域特定词汇或更强大的语言模型。将其替换为 BERT [2] 等替代编码器可以解锁这些能力，但这需要在计算资源有限的情况下将新编码器重新对齐到 CLIP 的冻结视觉空间，这是一个非平凡的任务。

在实际应用场景中，用户往往已经拥有针对特定领域或语言微调过的 BERT 模型——例如经过法律、医学等垂直领域语料继续训练的领域 BERT，或针对中文、阿拉伯语等语言优化的多语言 BERT 变体。这些定制模型承载了宝贵的领域知识，但由于缺乏与视觉表示的跨模态对齐，无法直接用于文本-视频检索。将其重新对齐到 CLIP 的冻结视觉空间是解锁这些检索能力的关键，但传统的完整微调需要大量计算资源和成对的图像-文本数据。因此，如何将已有的定制语言模型高效、轻量地适配到 CLIP 的视觉检索空间中，是一个具有明确实际意义的问题。

[†] 这些作者对本工作有同等贡献。张思远负责了方法设计、实验实施和结果分析；程亚迪提出了文本 - 视频检索的主题思想，负责了前、后端代码构建和测试。

本工作使用了生成式大语言模型进行辅助构建。具体而言，使用 Claude Code [24] 编码代理配合 DeepSeek-V4 [25] 大模型辅助代码编写、调试与文档撰写；使用 HY-MT1.5-1.8B [15] 翻译模型将 Flickr30k 英文描述翻译为中文，用于零样本跨语言检索能力验证。所有由生成式人工智能产出的内容均经过人工全面审查与修订，以确保其准确性、严谨性，并杜绝因模型幻觉导致的学术不端行为。

本工作作为 Python 应用开发基础课程设计，着力解决在单张 8GB GPU 上替换 CLIP 文本编码器的问题。我们的核心洞察是：对齐过程可以分解为两个轻量级阶段——首先在具有丰富标注的图像数据上将 BERT 适配到 CLIP 的视觉空间，然后高效地将对齐后的编码器迁移到视频领域。

我们采用 LoRA [4] 进行参数高效适配，仅训练插入 BERT Transformer 层的低秩适配器，同时保持所有预训练权重冻结。为弥补有限 GPU 内存下的小批量大小限制，我们使用基于队列的对比学习目标 [3]。然而，仅训练文本编码器会产生一个陈旧性问题：随着文本编码器的更新，队列中存储的文本嵌入变得过时。我们提出一种非对称队列设计来应对：遮蔽过时的文本嵌入，同时保留完整的新鲜图像队列——这些图像嵌入来自冻结的 CLIP 视觉编码器，因此始终是新鲜的。

我们的两阶段方法如下。第一阶段（图像对齐）：在 COCO Captions [9] 上使用 LoRA ($r=8$, 1.35M 可训练参数) 训练 BERT，使其与 CLIP 冻结的图像嵌入对齐，在 Flickr30k 上达到 60.48% 的文本-图像 R@1——超越了 CLIP 原生文本编码器的 57.90%。第二阶段（视频领域适配）：通过 Stack LoRA 将 COCO 对齐的 BERT 适配到 MSR-VTT 视频字幕，即通过权重合并冻结 COCO 训练的适配器，并叠加一个更小的秩为 2 的适配器 (0.63M 可训练参数)，仅学习视频相对于图片的领域偏移。最终模型在 MSVD 零样本视频检索中达到 28.13% t2i R@1，超过 CLIP 基线的 27.01%。

本工作的主要贡献如下：

1. 提出一种非对称队列设计，遮蔽过时的文本嵌入同时保留新鲜图像队列，在仅训练文本编码器的情况下，针对文本检索视频的能力实现有效的小批量对比学习。
2. 采用 Stack LoRA 解决图像到视频的领域适应问题，通过将预训练的 LoRA 适配器合并到基础权重后堆叠一个更小秩的新适配器，在保留第一阶段跨模态对齐的同时高效适应视频领域偏移；该设计同时提供了优秀的可插拔性。
3. 证明通过轻量级 LoRA 适配对齐到 CLIP 视觉空间的 BERT 编码器，在图像 (Flickr30k, 60.48% t2i R@1) 和视频 (MSVD, 28.13% t2i R@1) 零样本检索中均超过 CLIP 原生文本编码器，仅使用 0.63–1.35M 可训练参数，在单张 8GB GPU 上完成训练。

此外，由于本框架使用 BERT 作为文本编码器，通过替换为多语言 BERT 变体即可自然地支持多语言检索。我们展示了一个仅用英文描述训练的多语言 BERT 在零样本中文检索中取得远胜于随机的结果 (Flickr30k 上 27.22% t2i R@1)，证明了无需多语言训练数据的跨语言泛化能力。

二、相关工作

2.1 文本-视频检索

将图像-文本模型迁移到视频检索是一个活跃的研究方向。CLIP4Clip [16] 首次系统地研究了将 CLIP 适配到视频-文本检索，探索了包括均值池化、序列 Transformer 和跨模态注意力在内的多种相似度计算机制。一个重要发现是：在中小规模数据集（如 MSR-VTT 和 MSVD）上，简单的无参数帧嵌入均值池化优于更复杂的时序架构——因为在有限数据上引入额外的可训练参数可能损害预训练表示。这直接促使我们采用帧嵌入的均值池化作为视频表示。CLIP4Clip 同时采用均匀帧采样以保留帧间时序信息，这已成为视频检索领域的通用做法。ClipBERT [18] 提出随机稀疏采样策略，证明稀疏采样可以在不使用密集视频特征的情况下实现端到端学习。Frozen in Time [17] 引入了从单帧到时态上下文的课程学习调度，并提出了用于视频-文本预训练的 WebVid-2M 数据集。更近期的工作如 X-Pool [19] 使用跨模态注意力进行帧聚合，TS2-Net [22] 引入令牌移位和选择机制进行细粒度时空建模，VoP [20] 则采用仅 0.1% 可训练参数的提示调优实现高效视频-文本适配。

2.2 替换 CLIP 文本编码器

LiT [11] (Locked-image Tuning) 冻结预训练的图像编码器，仅训练文本编码器通过对比学习与之对齐，证明了锁定图像编码器始终优于微调。这直接激励了我们冻结 CLIP 视觉编码器的决定。与 LiT 将整个文本塔设为可训练不同，我们探索了更参数高效的方案：完全冻结 BERT，仅注入低秩适配器，以显著更少的可训练参数实现有竞争力的对齐。AltCLIP [5] 将 CLIP 的文本编码器替换为 XLM-R 以实现多语言能力，使用两阶段的蒸馏-对比训练流程。Chinese CLIP [6] 从头构建了一个中文专用的视觉-语言模型。我们的工作不同之处在于专注于将 BERT 轻量级适配到 CLIP 的现有嵌入空间，仅需少量训练数据和计算资源，同时支持图像和视频检索。

2.3 参数高效跨模态适配

LoRA [4] 提出将低秩分解矩阵插入到预训练 Transformer 层中，大幅减少了可训练参数。该方法已扩展到视频-语言任务：VoP [20] 在文本和视频编码器上引入提示调优，仅使用 0.1% 可训练参数。RAP [21] 提出了用于视频-文本微调的稀疏相关适配器与低秩调制。我们的工作引入 Stack LoRA，通过权重合并冻结预训练 LoRA 并叠加更小的适配器进行领域迁移——在不忘却原始对齐的情况下实现参数高效的视频领域适配。

2.4 基于队列的对比学习

MoCo [3] 引入了基于队列的字典用于对比学习，将字典大小与批量大小解耦。这在资源受限的环境中尤为重要。然而，当仅训练文本编码器且模型随时间演变时，队列中的文本嵌入会变得陈旧。我们的非对称队列设计直接解决了这一问题：在图像-文本方向上完全遮蔽文本队列，避免过时梯度污染，同时保留完整的图像队列用于文本-图像学习。由于 CLIP 视觉编码器冻结，队列中的图像嵌入始终保持新鲜，使得这种非对称性成为我们设置的自然选择。

三、 方法

3.1 两阶段训练流程

我们的框架将 CLIP 的文本编码器替换为 BERT 编码器后接一个轻量级投影头。训练分为两个阶段：

第一阶段——跨模态对齐 (图像)：我们在 COCO Captions (113k 图像, 567k 描述) 上训练，将 BERT 的输出空间与 CLIP 冻结的视觉嵌入空间对齐。该阶段建立了强大的跨模态初始化：在单张 8 GB GPU 上经过 30 个周期后，BERT 编码器单独在 Flickr30k 零样本检索上超越了 CLIP 原生文本编码器 (60.48% 对比 57.90%)，仅使用 1.35M 可训练 LoRA 参数。

第二阶段——视频领域适配：我们将 COCO 对齐的 BERT 适配到 MSR-VTT 视频描述。由于文本分布从 COCO 的简洁描述转向 MSR-VTT 更具描述性的视频叙述，继续训练有遗忘第一阶段建立的对齐的风险。为缓解这一问题，我们引入 **Stack LoRA**：首先将 COCO 训练的 LoRA 适配器 ($r=8$) 通过 `merge_and_unload()` 合并到 BERT 权重中，然后在其上叠加一个新的秩更小的 LoRA 适配器 ($r=2$)。合并后的 $r=8$ 适配器冻结在基础权重中，仅较小的 $r=2$ 适配器 (0.63M 可训练参数) 学习视频领域偏移。这既保留了一般性的跨模态对齐，又高效地适配了目标领域。

由于 CLIP 视觉编码器在两个阶段中均保持冻结，视频嵌入可一次离线预计算，并通过帧级关键特征的均值池化得到视频级表示，遵循 CLIP4Clip [16] 确立的标准做法。冻结的编码器还确保了对比队列中的图像/视频嵌入永远不会变陈旧。




图 1: Eureka-from-CLIP 训练流程。冻结的 CLIP 视觉编码器预计算视频帧或图像嵌入（永不过时）。可训练的 BERT 文本编码器配合 LoRA 产生文本嵌入。图像队列为文本-图像学习提供丰富的负样本，而过时的文本队列则被遮蔽。

3.2 模型架构

模型由三个组件组成：

冻结的 CLIP 视觉编码器。我们使用 OpenAI 的 ViT-B/32 作为冻结的视觉编码器。所有图像在线下一次编码，产生 512 维 L2 归一化嵌入。

BERT 文本编码器。我们使用 BERT-base (uncased) 作为文本编码器骨干网络。对于每个输入描述，从最后一层提取 BERT 的 [CLS] 令牌表示。

投影头。一个线性投影将 768 维的 BERT [CLS] 嵌入映射到 512 维共享空间，随后进行 L2 归一化。

LoRA 适配器 (第一阶段)。我们在 BERT 的 query、key、value 和 output 投影层中插入秩 $r = 8$ 、 $\alpha = 16$ 的 LoRA [4] 适配器。原始 BERT 权重保持冻结；仅 LoRA 参数和投影头可训练。这在 110.8M 总参数中产生了 1.35M 可训练参数。

Stack LoRA (第二阶段)。对于视频领域适配，我们首先使用 PEFT 的 `merge_and_unload()` 将训练好的 $r=8$ 适配器合并到 BERT 权重中（即对每个目标层计算 $W' = W + \frac{\alpha}{r}BA$ ，得到普通模型）。然后我们插入一个新的秩 $r = 2$ 、 $\alpha = 4$ 的 LoRA 适配器。合并后的 $r=8$ 权重冻结在基础模型中；仅 $r=2$ 适配器 (0.63M 可训练参数) 参与训练。这种堆叠设计使得在最小程度遗忘原始跨模态对齐的情况下实现高效的领域迁移。

3.3 损失函数设计

我们采用加权非对称 InfoNCE 损失 [7]，公式如下：

$$\mathcal{L} = (1 - \alpha) \cdot \text{CE}(\mathbf{S}_{i2t} \cdot \tau, \mathbf{y}) + \alpha \cdot \text{CE}(\mathbf{S}_{t2i} \cdot \tau, \mathbf{y}), \quad (1)$$

其中 $\mathbf{S}_{i2t} = \mathbf{I}\mathbf{T}^\top$ 为图像-文本相似度矩阵， $\mathbf{S}_{t2i} = \mathbf{T}\mathbf{I}^\top$ 为文本-图像相似度矩阵， $\tau = \exp(\gamma)$ 为可学习的温度参数（初始化为 $1/0.07$ ）， $\mathbf{y}$ 为对角标签集（正样本对），CE 表示交叉熵， α 为 t2i 权重。

我们设置 $\alpha = 0.75$ ，给予文本-图像方向 3 倍于图像-文本方向的权重。这一设计选择基于实际使用场景：在文本-图像检索中，用户提供文本查询，系统检索相关图像或场景，因此文本-图像召回是更重要的指标。

3.4 带文本过时遮蔽的队列设计

对比学习受益于大量负样本。遵循 MoCo [3]，我们维护一个过去（图像、文本）嵌入对的 FIFO 队列。然而，一个关键挑战出现了：文本编码器正在训练，因此队列中的文本嵌入是由早期、能力较弱的模型版本产生的。这些“过时”的文本嵌入如果用作图像-文本方向的负样本，可能会提供误导性的梯度信号。

我们的核心洞察是，这种过时性是方向相关的，且这种非对称性与我们的任务目标完美对齐：

- **图像-文本 (i2t)：**文本队列是过时的（文本编码器在演化）。我们在该方向上完全遮蔽文本队列，仅使用批次内负样本。这实际上意味着式1中的 $\mathbf{S}_{i2t}$ 计算为 $\mathbf{I}_{\text{batch}}\mathbf{T}_{\text{batch}}^\top$ ，不包含队列条目。由于 t2i 是我们的主要关注点，牺牲 i2t 的队列负样本是可接受的权衡。
- **文本-图像 (t2i)：**图像队列不是过时的，因为图像嵌入来自冻结的 CLIP 编码器。因此我们为该方法保留完整的图像队列，计算 $\mathbf{S}_{t2i} = \mathbf{T}_{\text{batch}}[\mathbf{I}_{\text{batch}}; \mathbf{I}_{\text{queue}}]^\top$ 。新鲜的图像队列提供了大量且一致的负样本集，直接提升了 t2i 性能。

这种非对称队列设计如表1所示。重要的是，训练哪个编码器以及保留哪一侧队列的选择并非随意。如果我们选择训练视觉编码器而冻结文本编码器，图像嵌入将变得过时，文本队列保持新鲜；此时队列将提升 i2t 而非 t2i——与我们的需求相反。因此，我们的配置（训练文本编码器，保留图像队列）在训练目标和架构设计之间建立了自然的对齐：冻结的 CLIP 保证了新鲜的图像队列，新鲜的图像队列保证了强大的 t2i 学习。通过遮蔽过时的文本嵌入，我们进一步避免损害 i2t 梯度，而这又带来双重收益——因为 t2i 已经在损失函数中获得了更高的权重（ $\alpha = 0.75$ ）。

表 1: 用于文本过时感知对比学习的非对称队列设计。

i2t 方向	t2i 方向
仅批次内负样本	批次内 + 队列负样本
$\mathbf{I}_{\text{batch}}\mathbf{T}_{\text{batch}}^\top$	$\mathbf{T}_{\text{batch}}[\mathbf{I}_{\text{batch}}; \mathbf{I}_{\text{queue}}]^\top$
无队列（避免过时文本）	图像队列（无过时问题）

我们额外应用了假负样本遮蔽：队列中与批次项共享相同图像 ID 的条目在相似度矩阵中被遮蔽（设为 $-\infty$ ），防止它们被当作负样本处理。

3.5 训练细节

第一阶段（图像对齐）：我们在 COCO train2017 描述（113k 图像，567k 描述）上使用单张 GeForce RTX 4060 笔记本电脑 GPU（8 GB VRAM）进行训练：

- 批量大小：128（8 GB VRAM 中 BERT-base + LoRA 可容纳的最大值）
- 优化器：AdamW，学习率 3×10^{-4} ，权重衰减 0.01

- 调度器：线性预热（34,536 步）后接余弦衰减至零
- 训练轮数：30
- 混合精度训练（AMP）
- 队列大小：49,152
- LoRA 秩：8, alpha: 16, dropout: 0.1

队列在损失计算后更新，防止当前批次项成为自身的负样本。预计算的 CLIP 图像嵌入避免了冗余的视觉前向传播。整个第一阶段训练约需 12 小时。

第二阶段（视频领域适配）：我们在 MSR-VTT 训练描述（9k 视频片段，180k 描述-片段对）上使用同样的 GPU：

- 批量大小：128
- 优化器：AdamW，学习率 1×10^{-5} （较低以保留对齐）
- 调度器：线性预热（4,000 步）后接余弦衰减
- 训练轮数：30
- 混合精度训练（AMP）
- 队列大小：49,152
- Stack LoRA 秩：2, alpha: 4, dropout: 0.1

我们在每个周期结束时在 MSVD（1,970 个视频，零样本）和 Flickr30k（1K 图像）上评估。对于视频，CLIP 逐帧关键帧嵌入通过均值池化得到视频级表示。

四、 实验

4.1 评估设置

我们在涵盖视频和图像检索的两个基准上进行评估：

MSVD [23] 是一个视频检索基准，包含来自 YouTube 的 1,970 个视频，每个视频约有 20 个人工标注描述。按照零样本协议，我们在标准的 670 视频测试集上评估，不在 MSVD 上进行任何训练。视频表示通过均值池化 12 个均匀采样的 CLIP 逐帧关键帧嵌入得到，遵循 CLIP4Clip [16] 验证的简单而有效的池化策略。

Flickr30k [8] 是一个图像检索基准，包含 31,783 张图像，每张有 5 条描述。我们使用标准的 1,000 张图像测试集进行零样本评估。

对于两个基准上的 CLIP 基线，我们使用官方 OpenAI ViT-B/32 模型。在视觉侧，这与我们 BERT 训练期间使用的冻结编码器相同。在文本侧，我们使用 CLIP 的原生 Transformer 文本编码器。

4.2 主要结果

表2展示了 MSVD 视频检索的主要结果。我们的两阶段方法取得了有竞争力的性能：

Stack LoRA 配置取得了最佳的视频检索性能（28.13% t2i R@1），超过了 CLIP 原生文本编码器基线（27.01%），同时在 i2t 方向上也有所提升（44.78% 对比 43.28%）。相比之下，简单地在 MSR-VTT 上继续微调完整的 r=8 适配器仅获得 26.95% t2i R@1，与 CLIP 持平，表明没有权重合并和重新堆叠策略，模型无法有效专门化到视频领域（参见表3中对应的原始 COCO 对齐遗忘情况）。

表 2: MSVD 上零样本文本-视频检索结果。所有方法使用相同的冻结 CLIP ViT-B/32 视觉编码器，采用均值池化的帧嵌入。

方法	t2i			i2t		
	R@1	R@5	R@10	R@1	R@5	R@10
CLIP 零样本（原生文本编码器）	27.01	50.62	60.73	43.28	60.30	66.27
我们的（第一阶段对齐，无视频适配）	24.17	49.15	60.78	32.69	52.54	60.45
+ 继续 LoRA (r=8) 在 MSR-VTT 上	26.95	54.57	66.35	44.33	63.73	70.15
+ Stack LoRA（冻结 r=8，叠加 r=2）	28.13	54.80	66.35	44.78	63.28	71.19

值得注意的是，仅经过 COCO 图像对齐的第一阶段模型在 MSVD 上 t2i R@1 为 24.17%，低于 CLIP 基线 (27.01%)，这表明图像域与视频域之间存在显著的分布差异。通过 MSR-VTT 视频字幕的进一步适配，Stack LoRA 不仅弥补了这一差距，还以 28.13% 的 t2i R@1 反超了 CLIP——验证了受控的领域适配策略能够有效恢复并在目标域上提升表示质量。

表3报告了 Flickr30k 图像检索结果，作为视频领域适配后跨模态对齐是否保持的辅助验证：

表 3: Flickr30k 测试集（1K 图像）上的零样本图像检索结果。第一阶段结果是什么视频适配前 COCO 训练模型的性能。

方法	t2i R@1	Flickr Δ （对比第一阶段）
CLIP 零样本（原生文本编码器）	57.90	—
我们的（第一阶段，COCO 对齐）	60.48	—
+ 继续 LoRA (r=8) 在 MSR-VTT 上	58.80	-1.68
+ Stack LoRA（冻结 r=8，叠加 r=2）	56.90	-3.58

在 COCO 上的第一阶段跨模态对齐产生了一个在 Flickr30k 上优于 CLIP 原生编码器的 BERT 文本编码器 (60.48 对比 57.90)。通过 Stack LoRA 进行视频领域适配后，Flickr30k 性能回落到 56.90（下降了 -3.58），这在预期之内——因为领域从 COCO 的静态照片转移到 MSR-VTT 的动态视频叙述。关键在于，这种领域偏移正是 Stack LoRA 所要捕捉的信号：低秩约束迫使适配器向视频领域专门化，Flickr 上的退化是这种专门化的自然伴随结果，而非局限性的证据。

4.3 消融实验：非对称损失和队列设计的影响

配置	t2i R@1	i2t R@1
我们的（完整）	60.48	74.60
无遮蔽（允许过时文本队列）	44.32	53.80
无队列	55.06	72.10

表 4: 框架中各队列组件的消融实验。

表4总结了消融实验。移除文本过时遮蔽（“无遮蔽”）严重降低了两个方向的性能，因为过时的文本嵌入污染了梯度。值得注意的是，这种设置比“无队列”更差，表明未遮蔽的队列对学习的危害超过没有队列。在没有队列的情况下（“无队列”），缺乏丰富的负样本主要损害了 t2i。

表5考察了损失权重 α 的影响。将 α 从 0.25 增加到 0.75 仅获得了 +1.20 t2i R@1 的提升（从 59.28 到 60.48），同时伴随着从 i2t 到 t2i 的相应转移。 $\alpha=0.50$ 的配置达到了 60.26 t2i R@1，仅比完整的 $\alpha=0.75$

α (t2i 权重)	t2i R@1	i2t R@1
0.25	59.28	76.10
0.50	60.26	75.90
0.75	60.48	74.60

表 5: 非对称损失权重 α 对检索性能的影响。

设置低 0.22 点，表明非对称损失权重相比队列设计的贡献要小得多。

结合表6中的参数放置消融，这些结果建立了一个更广泛的层级：如何将有限的可训练容量分布在 BERT 层之间（LoRA 对比 MLP，表6）以及如何设计对比队列（表4）在决定最终检索性能方面均主导了显式的损失重加权（表5）。

4.4 参数消融：参数分布（LoRA 对比 MLP 投影）

为了隔离 LoRA 的性能提升是源于额外的可训练容量还是其在 BERT 内的逐层分布，我们将所有 LoRA 适配器替换为一个三层 MLP 投影头（768 $\rightarrow$ 704 $\rightarrow$ 704 $\rightarrow$ 512），其可训练参数数量相当（约 1.40M 对比 LoRA 配置的约 1.35M）。MLP 插入在 BERT 的 [CLS] 池化之后，替换了原始的线性投影头和 LoRA 适配器。所有其他超参数保持不变。

表6报告了结果。MLP 投影仅达到 39.92% t2i R@1 和 51.3% i2t R@1，远低于 LoRA 配置（60.48% / 74.60%），甚至低于”无队列”消融（55.06% / 72.10%）。t2i R@1 上 20 多个百分点的下降表明，可训练参数的架构放置远重于其原始数量。LoRA 的有效性在于它能够适配 BERT 所有 12 个 Transformer 层的内部表示，而 MLP 将所有可训练容量集中在一个事后投影中，无法弥补冻结的 BERT 骨干网络与 CLIP 嵌入空间之间的不对齐。

有趣的是，MLP 配置在早期周期后验证损失也出现平台期（val_loss 在第 5 个周期达到最小值 2.44，之后逐渐增加），表明事后投影很快耗尽了其表示能力。相比之下，LoRA 配置在整个 30 周期的训练过程中持续改善。

表 6: 消融实验：LoRA 对比 MLP 投影（可训练参数数量相当）。两种模型均在 COCO 上训练，在 Flickr30k 上进行零样本评估。

方法	t2i R@1	t2i R@5	t2i R@10	i2t R@1	i2t R@5	i2t R@10
LoRA（我们的）	60.48	84.96	91.00	74.60	92.90	96.60
MLP 投影	39.92	68.88	78.68	51.30	81.00	89.20

五、 讨论

5.1 队列非对称性主导检索优化

表4和5中的消融结果揭示了设计选择之间的明确层级。完全移除队列使 t2i R@1 下降了 5.42 点（从 60.48 降到 55.06），而将 t2i 权重 α 从 0.75 降至 0.50 仅移动了 0.22 点（从 60.26 到 60.48，表5）。队列带来的性能增益远大于显式损失重加权所获得的。

文本过时遮蔽更为关键：允许过时的文本嵌入进入队列（”无遮蔽”）使 t2i R@1 骤降至 44.32，下降了 16.16 点。未遮蔽的队列比完全没有队列更差，表明来自过时文本嵌入的陈旧梯度不仅提供递减的收益，反而会主动损害学习。

这些结果表明，我们框架中最大的性能提升源自非对称队列机制，而非显式的损失重加权。这一洞察同样适用于视频领域，其中相同的冻结 CLIP 视觉编码器保证了队列中视频嵌入的新鲜度。

5.2 为什么损失重加权不如预期重要？

α 的相对温和影响可以通过检查训练期间的损失动态来理解。图像队列为文本-图像方向提供大量额外的负样本，使得每个批次内的 t2i 任务天然比 i2t 更困难。这种非对称性源自大型图像队列，它为 t2i 分支引入了数十万个额外的图像负样本。因此，原始 t2i 损失在训练过程中始终大于对应的 i2t 损失。图2绘制了整个训练轨迹中未加权的损失比 L_{t2i}/L_{i2t} ($\alpha=0.75$)。值得注意的是，该比率从第一个周期的约 3.3 倍上升到收敛时的超过 13.5 倍，所有周期的均值为 11.86 倍。这一趋势违反直觉：尽管为 t2i 分支分配了更大的优化权重 ($\alpha=0.75$)，原始 t2i 损失不仅保持更高，而且在整个训练过程中与 i2t 的差距持续扩大。如果损失加权是主导因素，人们会预期原始 t2i 损失随着训练进行而趋近于 i2t 损失。相反，不断增长的比率表明队列引发的难度压倒了显重重加权的补偿，证实了队列非对称性——而非损失加权——是 t2i 优化偏差的主要驱动因素。

这一观察解释了为什么 $\alpha=0.50$ 配置 (表5) 达到了 60.26 t2i R@1，仅比 $\alpha=0.75$ 低 0.22 点。队列通过非对称地向 t2i 提供更多负样本，作为一种隐式正则化器，降低了对显式损失加权的需求。




图 2: 训练期间原始 (未加权) 文本-图像损失与图像-文本损失的比值 L_{t2i}/L_{i2t} ($\alpha=0.75$)。尽管存在偏向 t2i 的显式优化偏差，该比率从第一个周期的约 3.3 倍上升到收敛时的超过 13.5 倍，均值为 11.86 倍 (虚线)。这一不断扩大的差距表明队列引发的非对称性主导了损失重加权的效果。

5.3 资源约束自然导致非对称设计

非对称队列并非任意的设计选择。相反，它从我们资源受限的训练设置中自然产生：冻结 CLIP 视觉编码器使图像和视频嵌入始终保持新鲜，而演化的文本编码器则使队列中的文本嵌入过时。在这种设置下，仅保留图像队列成为最自然的解决方案。

5.4 Stack LoRA 实现高效领域迁移

两阶段结果 (表2、3) 揭示了一个清晰的模式：Stack LoRA 在视频检索上取得了强劲的性能 (MSVD 上 28.13 t2i R@1)，同时收敛速度快于全参数替代方案 (25 个周期对比 28 个周期)。相比之下，在没有

权重合并和重堆叠的情况下继续微调完整的 $r=8$ 适配器仅得到 26.95 t2i R@1——与 CLIP 基线持平，比 Stack LoRA 低 1.18 点——表明权重合并和堆叠策略对于有效的领域专门化至关重要。

Stack LoRA 的较小 $r=2$ 适配器，由于其有限的表示容量，只能捕捉训练数据中最显著的信号——而最显著的信号恰恰就是这种图像到视频的领域偏移。低秩约束迫使适配器强烈地致力于目标领域，产生更快的收敛速度（优化器搜索空间更小）和更高的视频检索性能（每个可训练参数都专注于视频偏移）。这种专门化自然地将文本嵌入分布从 COCO 对齐空间向视频领域移动，这解释了观察到的 Flickr 退化 (-3.58) 是一种可预测的伴随结果而非局限性。

关键在于，这种可插拔性是 LoRA 适配的自然属性。COCO 对齐的 $r=8$ 适配器和 MSR-VTT 的 $r=2$ 堆叠是独立的低秩矩阵，可以在推理时以极小的内存开销进行加载、切换或组合。当任务是图像检索时，仅需要 $r=8$ 适配器；当领域转移到视频时，可以在不丢弃原始对齐的情况下将 $r=2$ 堆叠插在其上。由于每个适配器只占完整模型大小的一小部分（ $r=8$ 为 1.35M 参数， $r=2$ 为 0.63M），且两者都能舒适地放在单张 8GB GPU 上，用户可以维护多个领域特定适配器并根据需要部署——这是参数高效理念的一个实际体现。

5.5 扩展到多语言检索

我们的框架依赖 BERT 作为文本编码器，这自然地扩展到多语言场景，因为 BERT 提供了多语言变体（如 bert-base-multilingual-cased），具有跨语言的共享分词器和嵌入空间。为探索这一能力，我们在相同的英文 COCO 描述上使用相同的超参数训练多语言 BERT，并在中文 Flickr30k 上进行零样本评估——其中中文描述通过 HY-MT1.5 [15] 翻译原始英文描述得到。

表 7: Flickr30k 上的零样本多语言检索。所有模型仅使用英文 COCO 描述进行训练。

方法	t2i R@1	i2t R@1
BERT-uncased（英文，我们的）	60.48	74.60
多语言 BERT（英文，我们的）	57.08	69.00
多语言 BERT（中文，我们的）	27.22	39.20

表7报告了多语言结果。多语言 BERT 在英文上达到 57.08% t2i R@1，比 BERT-uncased (60.48%) 低 3.4 点，这归因于多语言分词器对英文文本的子词效率降低。更重要的是，其在中文上达到了 27.22% t2i R@1——显著高于 0.1% 的随机基线，且接近其英文性能的一半——尽管训练期间从未见过中文文本。这证明了有意义的零样本跨语言迁移：共享的多语言嵌入空间在通过仅英文的对比学习对齐到 CLIP 视觉表示后，能够泛化到非英文查询。

这些结果进一步说明了我们基于 BERT 的框架的可插拔性。由于 LoRA 适配器作用于 BERT 的内部表示而非语言特定特征，相同的英文训练适配器可以不加修改地应用于多语言 BERT。在视频检索场景中，这意味着对齐到 CLIP 视觉空间的多语言 BERT 可以使用多种语言的查询检索视频，且 Stack LoRA 视频领域适配器随基础模型一同迁移，无需多语言视频训练数据。

5.6 帧采样策略的影响：关键帧检测与均匀采样对比

我们的指导教师建议使用基于场景检测的关键帧采样替代均匀帧采样，认为场景感知的帧选择能够减少长静态镜头中的冗余，更有效地利用有限 (12 帧) 的帧预算。为验证这一假设，我们使用 PySceneDetect 的 ContentDetector（阈值为 27.0）检测场景边界：按场景时长比例分配帧预算，确保每个场景至少采样一帧，并在每个场景内均匀采样。该策略产出的帧嵌入经过与均匀采样完全相同的均值池化流程和对比学习训练。

表8展示了两种采样策略在 MSVD 零样本视频检索上的对比结果。两种策略在所有指标上均高度接近：t2i R@1 (28.15 对比 28.16)、t2i R@5 (54.94 对比 54.93)、t2i R@10 (66.78 对比 66.75) 以及 i2t

各指标。Flickr30k 图像检索上 (56.48 对比 56.90) 的差异同样处于正常波动范围内。两种配置之间不存在统计学显著的性能差距。

表 8: 帧采样策略对比 (MSVD 零样本视频检索, Stack LoRA 配置)。两种策略均使用 12 帧预算和均值池化。

采样策略	t2i			i2t		
	R@1	R@5	R@10	R@1	R@5	R@10
均匀采样 (我们的, Stack LoRA)	28.16	54.93	66.75	45.97	64.33	72.09
关键帧采样 (场景检测)	28.15	54.94	66.78	45.22	64.03	71.34

这一结果的接近性可能反映多个因素。首先, MSVD 视频时长较短 (平均约 10 秒), 场景数量有限, 场景感知采样与均匀采样的实际帧选择难以产生显著差异。其次, CLIP 的 ViT-B/32 编码器独立处理每帧并捕捉了完整的场景级语义信息, 因此改进帧覆盖的边际收益有限。第三, 均值池化操作将所有帧嵌入聚合为单一向量, 无论帧集如何选择都进一步平滑了差异。第四, CLIP4Clip [16] 此前已观察到, 在中小规模视频基准 (MSR-VTT、MSVD) 上, 简单的均匀采样配合均值池化已具有竞争力, 我们的实验结果将这一观察扩展到了场景检测关键帧这一特定策略上。

这一结果揭示了一个重要的实践启示: 在帧预算小且视频时长短的资源受限场景中, 采样策略的选择对检索性能的影响可忽略不计。因此, 运行场景检测带来的额外计算开销在此评估设置下并不合理。然而, 在视频更长、场景更多样化的基准上, 场景感知采样可能仍具有优势——这留待未来工作验证。

六、 局限性

我们承认本工作存在若干局限性。首先, 我们的视频评估限于 MSVD, 这是一个相对较小的基准 (1,970 个视频; 我们使用标准的 670 视频测试集)。更大且更多样化的视频检索基准如 MSR-VTT 1K-A 或 ActivityNet 将提供更全面的评估。使用简单的均值池化进行帧聚合也限制了我们捕捉视频中时序结构的能力。

其次, 我们的模型仅在第一阶段使用 COCO train2017 描述 (113k 图像, 567k 描述) 进行训练, 这是一个领域多样性有限的单一数据集。虽然这使我们能够在严格的计算约束下展示方法的有效性, 但在更多样化的语料库上训练可能会提高泛化能力。

第三, Flickr30k 上的评估是在 1K 测试集上进行的, 其中 R@K 指标的方差可能大于更大基准上的方差。

第四, 消融实验报告的是无置信区间的单次运行结果。由于计算限制, 每个配置仅评估一次而非使用多个随机种子, 因此观察到的差异应谨慎解读。

第五, 我们的多语言评估限于单一数据集 (Flickr30k) 上的中文, 使用的是机器翻译而非人工标注的描述。HY-MT1.5 [15] 的翻译质量可能引入噪声, 低估了真正的跨语言迁移能力, 在更多语言和视频基准上的评估留待未来工作。

七、 未来工作

在此工作之外, 几个方向值得探索。首先, 简单的帧嵌入均值池化可以替换为更复杂的时序聚合方法, 例如在帧嵌入序列上的轻量级 Transformer 或文本查询与视频帧之间的跨模态注意力 [19]。这可以更好地捕捉运动和事件结构, 尤其在长视频上。

其次, 在更大更多样化的视频基准 (如 MSR-VTT 1K-A、ActivityNet、DiDeMo) 上评估将提供更全面的泛化能力评估。将框架扩展到支持多语言视频检索 (即不同语言的查询从同一个视频池中检索) 是

我们基于 BERT 的方法的自然应用。

第三，探索更激进的参数效率方案（如提示调优 [20] 或稀疏适配器 [21]）可以进一步降低适配成本，而将 Stack LoRA 应用于其他领域迁移场景（如图像 → 医学、英文 → 多语言）将测试其通用性。

八、 结论

本文介绍了 Eureka-from-CLIP，一个在严格资源约束下将 CLIP 文本编码器替换为轻量级 BERT 适配器以进行零样本文本-视频检索的框架。通过两阶段方法——首先在 COCO 图像上将 BERT 对齐到 CLIP 的视觉空间（第一阶段），然后通过 Stack LoRA 进行视频领域适配（第二阶段）——我们在两个基准上取得了有竞争力的结果：Flickr30k 图像检索 60.48% t2i R@1（超越 CLIP 的 57.90%）和 MSVD 视频检索 28.13% t2i R@1（优于 CLIP 的 27.01%），全部仅使用 0.63–1.35M 可训练参数，在单张 8 GB GPU 上完成。

我们的文本过时感知的非对称队列设计解决了仅训练文本编码器时对比队列面临的基本挑战：通过遮蔽过时的文本嵌入同时保留新鲜的图像队列，我们防止了梯度污染并最大化丰富负样本的效益。Stack LoRA 展示了冻结预训练适配器并堆叠更小的适配器可以在极小的计算开销下高效地将跨模态对齐迁移到新领域。

我们的方法为用任意 BERT 变体替换 CLIP 文本编码器提供了一种实用、可泛化的方案，使视频、多语言和领域特定检索应用无需昂贵的从头训练。

致谢

作者感谢 Jie Lei 在本项目中的指导与有益讨论。本工作作为浙江工业大学 Python 应用开发基础课程设计完成。

参考文献

- [1] A. Radford, J. W. Kim, C. Hallacy, A. Ramesh, G. Goh, S. Agarwal, G. Sastry, A. Askell, P. Mishkin, J. Clark, G. Krueger, and I. Sutskever. Learning transferable visual models from natural language supervision. In *ICML*, 2021.
- [2] J. Devlin, M.-W. Chang, K. Lee, and K. Toutanova. BERT: Pre-training of deep bidirectional transformers for language understanding. In *NAACL-HLT*, 2019.
- [3] K. He, H. Fan, Y. Wu, S. Xie, and R. Girshick. Momentum contrast for unsupervised visual representation learning. In *CVPR*, 2020.
- [4] E. J. Hu, Y. Shen, P. Wallis, Z. Allen-Zhu, Y. Li, S. Wang, L. Wang, and W. Chen. LoRA: Low-rank adaptation of large language models. In *ICLR*, 2022.
- [5] Z. Chen, G. Liu, B.-W. Zhang, F. Ye, Q. Yang, and L. Y. Wu. AltCLIP: Altering the language encoder in CLIP for extended language capabilities. *arXiv preprint arXiv:2211.06679*, 2022.
- [6] A. Yang, J. Pan, J. Lin, R. Men, Y. Zhang, J. Zhou, and C. Zhou. Chinese CLIP: Contrastive vision-language pretraining in Chinese. *arXiv preprint arXiv:2211.01335*, 2022.
- [7] A. van den Oord, Y. Li, and O. Vinyals. Representation learning with contrastive predictive coding. *arXiv preprint arXiv:1807.03748*, 2018.

- [8] P. Young, A. Lai, M. Hodosh, and J. Hockenmaier. From image descriptions to visual denotations: New similarity metrics for semantic inference over event descriptions. *Transactions of the Association for Computational Linguistics*, 2:67–78, 2014.
- [9] T.-Y. Lin, M. Maire, S. Belongie, J. Hays, P. Perona, D. Ramanan, P. Dollár, and C. L. Zitnick. Microsoft COCO: Common objects in context. In *ECCV*, 2014.
- [10] A. Conneau, K. Khandelwal, N. Goyal, V. Chaudhary, G. Wenzek, F. Guzmán, E. Grave, M. Ott, L. Zettlemoyer, and V. Stoyanov. Unsupervised cross-lingual representation learning at scale. In *ACL*, 2020.
- [11] X. Zhai, X. Wang, B. Mustafa, A. Steiner, D. Keysers, A. Kolesnikov, and L. Beyer. LiT: Zero-shot transfer with locked-image text tuning. In *CVPR*, 2022.
- [12] X. Zhai, B. Mustafa, A. Kolesnikov, and L. Beyer. Sigmoid loss for language image pre-training. In *ICCV*, 2023.
- [13] P. Sharma, N. Ding, and R. Soricut. Conceptual captions: A cleaned, hypernymed, image alt-text dataset for automatic image captioning. In *ACL*, 2018.
- [14] B. Thomee, D. A. Shamma, G. Friedland, B. Elizalde, K. Ni, D. Poland, B. Borth, and L.-J. Li. YFCC100M: The new data in multimedia research. *Communications of the ACM*, 59(2):64–73, 2016.
- [15] Tencent Hunyuan Team. HY-MT1.5 technical report. *arXiv preprint arXiv:2512.24092*, 2025.
- [16] H. Luo, L. Ji, M. Zhong, Y. Chen, W. Lei, N. Duan, and T. Li. CLIP4Clip: An empirical study of CLIP for end to end video clip retrieval. *Neurocomputing*, 508:293–304, 2022.
- [17] M. Bain, A. Nagrani, G. Varol, and A. Zisserman. Frozen in time: A joint video and image encoder for end-to-end retrieval. In *ICCV*, 2021.
- [18] J. Lei, L. Li, L. Zhou, Z. Gan, T. L. Berg, M. Bansal, and J. Liu. Less is more: ClipBERT for video-and-language learning via sparse sampling. In *CVPR*, 2021.
- [19] S. K. Gorti, N. Vouitsis, J. Ma, K. Golestan, M. Volkovs, A. Garg, and G. Yu. X-pool: Cross-modal language-video attention for text-video retrieval. In *CVPR*, 2022.
- [20] S. Huang, B. Gong, Y. Pan, J. Jiang, Y. Lv, Y. Li, and D. Wang. VoP: Text-video co-operative prompt tuning for cross-modal retrieval. In *CVPR*, 2023.
- [21] M. Cao, H. Tang, J. Huang, P. Jin, C. Zhang, R. Liu, L. Chen, X. Liang, L. Yuan, and G. Li. RAP: Efficient text-video retrieval with sparse-and-correlated adapter. In *ACL Findings*, 2024.
- [22] Y. Liu, P. Xiong, L. Xu, S. Cao, and Q. Jin. TS2-Net: Token shift and selection transformer for text-video retrieval. In *ECCV*, 2022.
- [23] D. Chen and W. Dolan. Collecting highly parallel data for paraphrase evaluation. In *ACL*, 2011.
- [24] K. Chatlatanagulchai, K. Thonglek, I. Reid, K. Kashiwa, P. Leelaprute, A. Rungsawang, B. Manaskasemsak, and H. Iida. On the use of agentic coding manifests: An empirical study of Claude Code. *arXiv preprint arXiv:2509.14744*, 2025.
- [25] DeepSeek-AI. DeepSeek-V4: Towards highly efficient million-token context intelligence. Technical report, 2026. Available at <https://huggingface.co/deepseek-ai/DeepSeek-V4-Pro>.

九、超参数选择

我们评估了 $\alpha \in \{0.25, 0.50, 0.75\}$ 。尽管 $\alpha=0.50$ 已经达到了可比的性能，但 $\alpha=0.75$ 产生了最高的 t2i R@1，因此被最终模型采用。表9总结了本框架使用的关键超参数。所有实验使用在 COCO 描述上训练的 LoRA 秩 $r = 8$ ，种子为 42。

表 9: 关键超参数。CLIP ViT-B/32 (OpenAI) 基线: t2i R@1 57.90%, i2t R@1 76.90%。

超参数	值	描述
批量大小	128	8 GB VRAM 下最大
学习率	3×10^{-4}	AdamW, 余弦衰减
权重衰减	0.01	
预热步数	34,536	线性预热
训练轮数	30	
LoRA 秩 r	8	
LoRA α	16	
LoRA dropout	0.1	
LoRA 目标	Q, K, V, O	BERT 线性层
队列大小	49,152	FIFO 对比队列
t2i 权重 α	0.75	式1
温度 τ 初始值	1/0.07	可学习 $\tau = \exp(\gamma)$
AMP	true	混合精度训练